

# 蚂蚁集团可观测性与时序数据库实践

陈伟荣 2023 年 1 月

### 分享目录

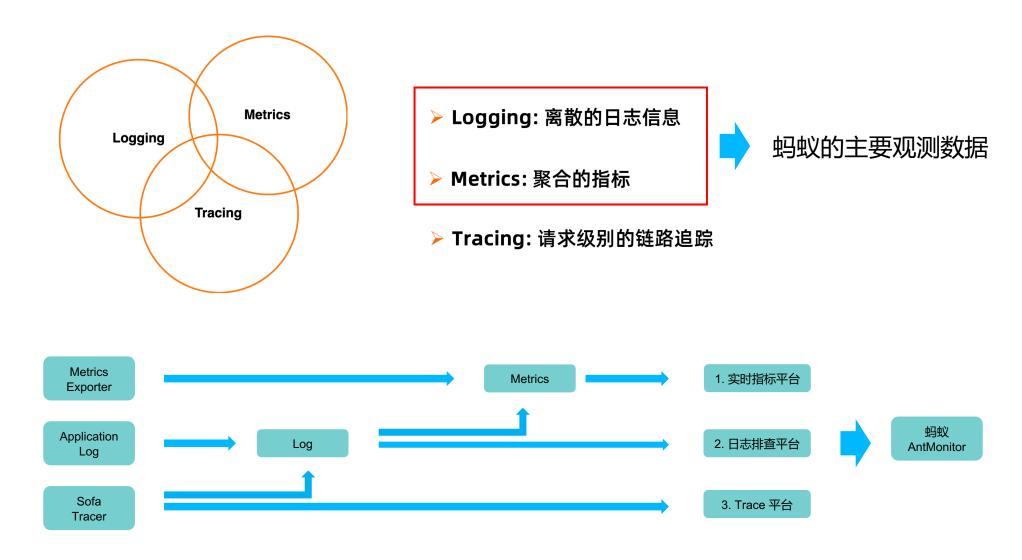


- 1. 可观测平台整体架构
- 2. 实时采集与计算系统
- 3. 自研开源时序数据库 <u>CeresDB</u>
- 4.开源计划

### 可观测平台整体架构

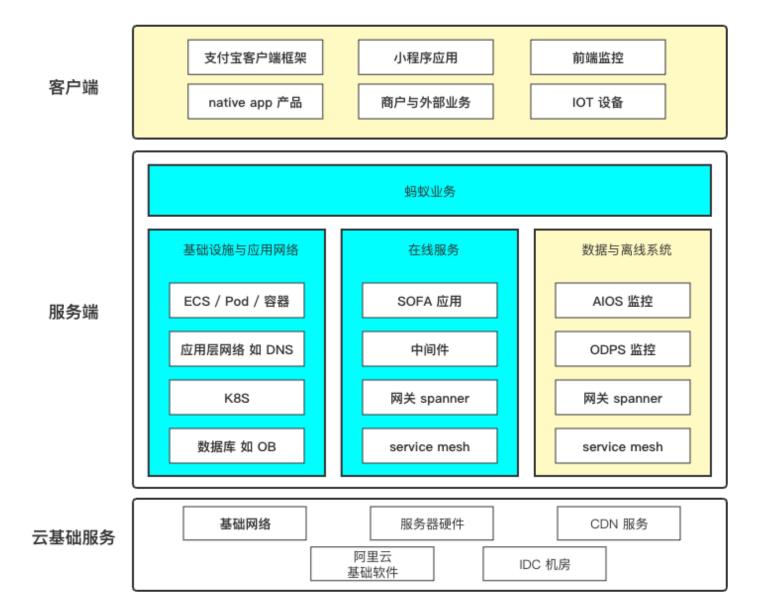


### 整体技术体系介绍



### 可观测平台整体架构





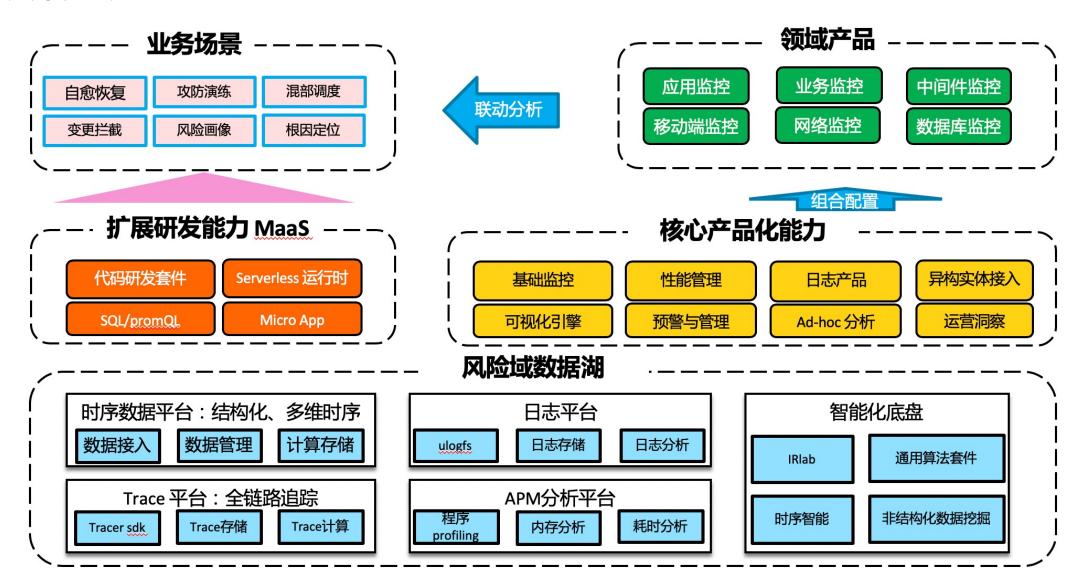
#### 业务覆盖情况

初步形成公司层面全局统一的的可观测平台。业务层面涵盖服务端与客户端。系统层面覆盖了在线系统与大数据、中间件与云基础设施。

### 可观测平台整体架构

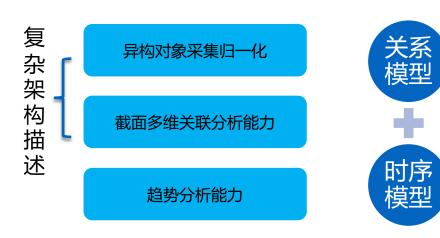


#### 整体领域架构划分



# 实时采集与计算系统——多维时序模型抽象





#### 核心数据模型设计

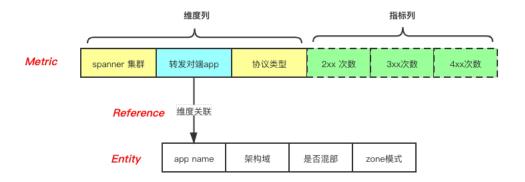
- ・ 监控对象 <Entity>
- 监控指标 <Metric>
- ・ 关联关系 <Reference>

#### 表达形式

・ 维度计算 ( container.ldc.city )

多维时

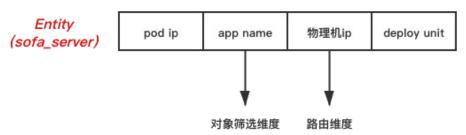
序模型



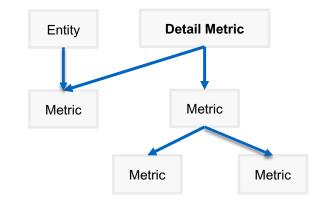
#### 技术实现:

#### Entity 维度驱动的采集

对象范围 < Entity (维度计算) > 让谁采集 < 维度 + 标签化路由> 怎么采集 < 插件化>



#### 可关联 Entity 维度的计算拓扑结构

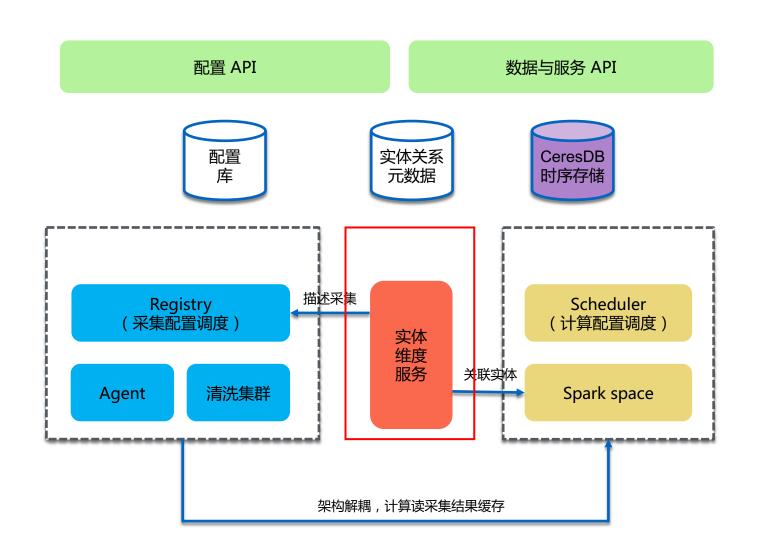


#### Transform模型

- GroupBy
- ・ Join Entity 后 GroupBy

# 实时采集与计算系统——多维时序模型实现



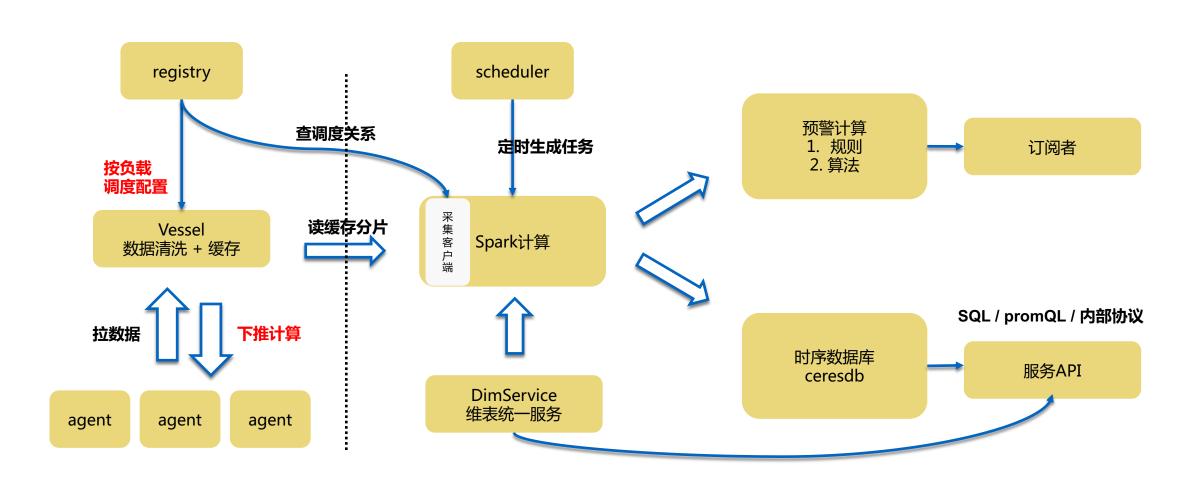


#### 与普通 Prometheus 对比

- ・ 维度 Join
- ・ 实体关联
- ・描述化采集
- 预计算
- ・非结构化数据处理

# 实时采集与计算系统——实时指标技术架构





### 实时采集与计算系统——实时指标技术架构





▶ 集群热点引起数据下跌,热点难以缓解

**集群利用率低**,资源浪费

问题

监控不准影响业务决策

#### 无法解决热点问题



基于数量/权重

哈希/一致性哈希

> 按规格



回到问题本身,分解热点

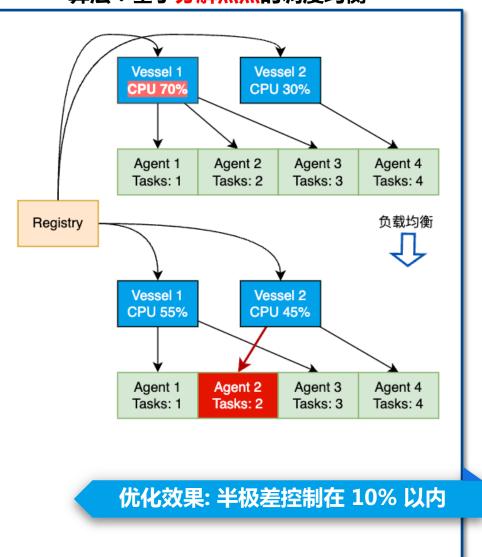
> CPU 是热点的衡量标准

新思路

> 随机性

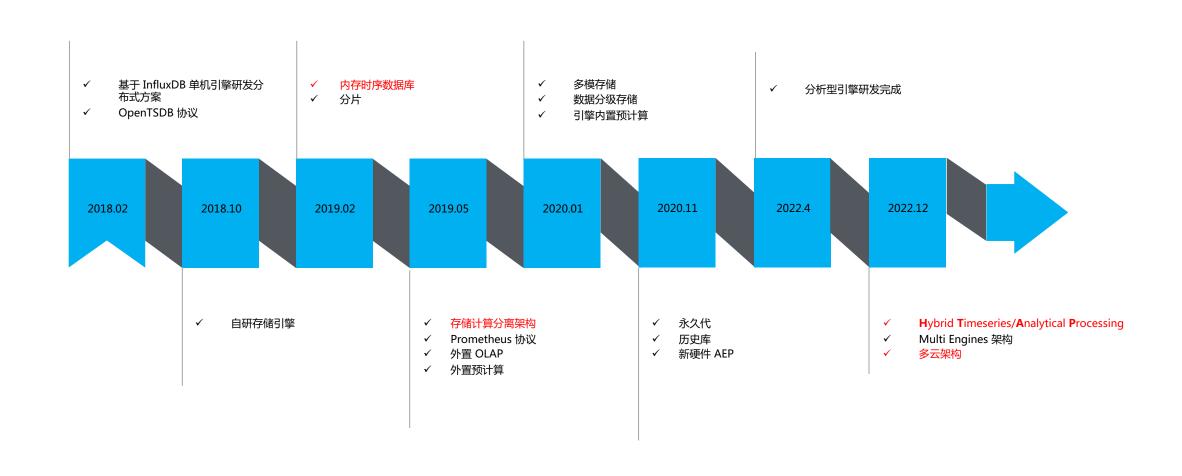
对比项	分解热点	基于数量/哈希	基于权重
收敛	慢	快	不
极差	小	大	大
热点	最终修复	无法修复	无法修复
稳定性	头尾抖动有冷点	非常稳定	整体抖动
正确性	偶尔错误 <mark>最终正确</mark>	运气	错误

#### 算法:基于分解热点的调度均衡



### 时序数据库 CeresDB





### 时序数据库 CeresDB



#### 为什么自研(2018 - 2021年)

#### 1. Influxdb 的问题

- 查询语法丰富度不够
- 优化参数较少,需要深度hack源码
- 大体量数据下运维比如重启等能力不足
- · Golang 本身GC等行为对延迟和抖动影响较大

#### 2. 海量数据架构带来的挑战

- 分钟级别百亿点对延迟和性能的敏感性
- 存储的分布式能力,水平扩容与集群运维能力

#### 3. 新业务场景的需求

• 金融时序分析



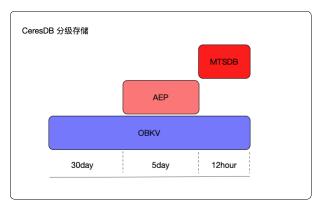
### 使用 Rust 研发时序 数据库引擎 CeresDB

• 此时我们的技术方向仍然是沿着 InfluxDB 类似的传统时序数据方向

### 时序数据库 CeresDB



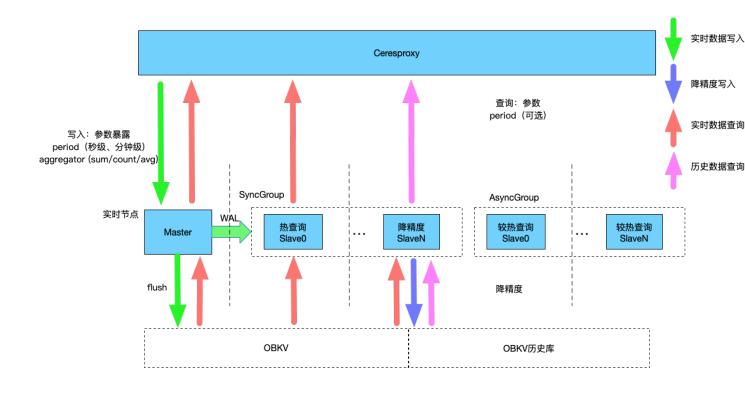
#### 概念模型:



数据压缩:



#### 存算分离与低成本架构实现:



- > 难题
- ✓ 查询延时高
- ✓ 写入性能
- ✓ 数据压缩比

- ▶ 解法
- ✓ MTSDB
- ✓ 异步写入 + RPL
- ✓ 自动降精度

### 时序数据库 CeresDB——混合负载时序数据库



### 挑战与方向(2022)

#### 重大改版(2022年)

- 1. 需求升级:时序场景分析型诉求的 突出(典型:用户根据监控指标进 行问题定位,成本分析)
- 2. 云原生趋势与多环境的需求
- 3. 计算存储分离的进一步升级
- 对 SQL 协议与各种协议兼容的诉求

#### HTAP 混合负载

• 原生支持 AP 分析与传统时序工作负载,有效解决高维分析查询在传统时序数据库中的性能瓶颈。简化 用户技术架构(实时计算与离线计算相应系统)。

#### 分布式 & 高可用

实现现代的分布式架构,保障元数据一致性。支持数据和计算节点的调度,主备,水平伸缩等 能力。同时支持分布式的 WAL, 保证数据的高可靠性。

#### 云原生 & 存算分离

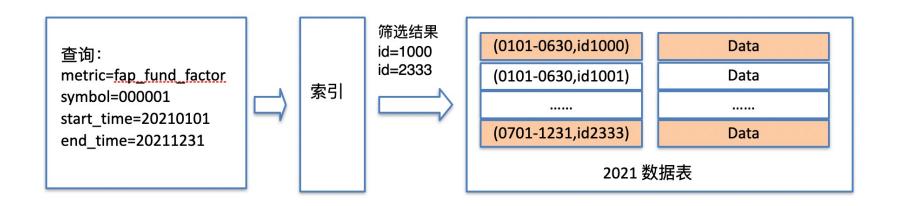
• 结合云原生和数据库发展技术趋势,设计上就需要考虑架设在现代的云服务之上。不同于单纯 的 Cloud Hosting, 我们需要将数据存放在对象存储,解耦计算资源。这将极大提升系统整体 的弹性能力,并降低成本。

#### 低成本高性能

虽然过去 CeresDB 在低成本和高性能上都有多年技术积累,但是在新的架构上,我们仍然需要 找到技术上的资源成本最优。具体技术包括分级存储,时序数据专用压缩,AEP 新硬件等。性 能层面平衡 AP 分析能力和传统时序负载也是个重要命题。

### 时序数据库 CeresDB——混合负载时序数据库





#### 传统时序数据库技术特点

- ・ Tag 与 Field 分开存储
- ・ Tag 上构建倒排索引
- · 查询通过倒排索引定位时间线,再根据线进行查 询Field
- · 主要面向实时监控场景,对时间线较少的场景较 友好
- ・ 定制协议 ( OpenTSDB / promQL / influxQL )

#### 问题:难以支持海量时间线

- ・索引膨胀
- · 写入性能差, 创建复杂的索引
- · 查询性能差,索引筛选效果差

#### 问题:协议痛点多

- 查询能力弱,协议表达能力无保障
- ・字段类型受限
- ・特化协议学习成本高



### 时序数据库 CeresDB——混合负载时序数据库



### 混合负载时序数据库数据存储结构

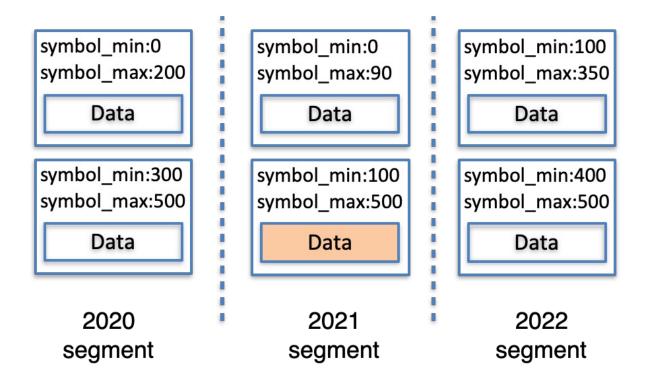
#### 列式存储,无需倒排索引即可查询

- 提供海量时间线场景下的数据分析能力
- 依赖<mark>剪枝</mark>和高效的Scan,加速分析查询

#### 表级别支持数据在时间上分布的控制

- 一个集群即可应对多种不同TTL的管理
- 每个表根据数据分布自适应创建segment,数据按照时间进行合理的分布,可加速查询

查询: metric=fap\_fund\_factor symbol=120 start\_time=20210101 end\_time=20211231



### 时序数据库 CeresDB——单节点引擎架构



#### 一些关注点

#### 1. WAL

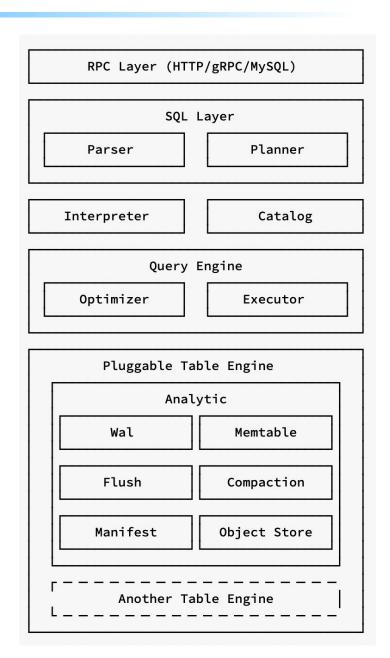
- CeresDB 处理数据的模型是 WAL + MemTable
- WAL 支持多种模式包括本地 Rocksdb ,分布式 kafka、
  OBKV

#### 2. 对象存储

- Flush 生成的 SST 文件需要被写入持久化存储
- 对底层存储设备的抽象是对象存储,包括多种实现:本地 文件,阿里云 OSS,分布式文件系统

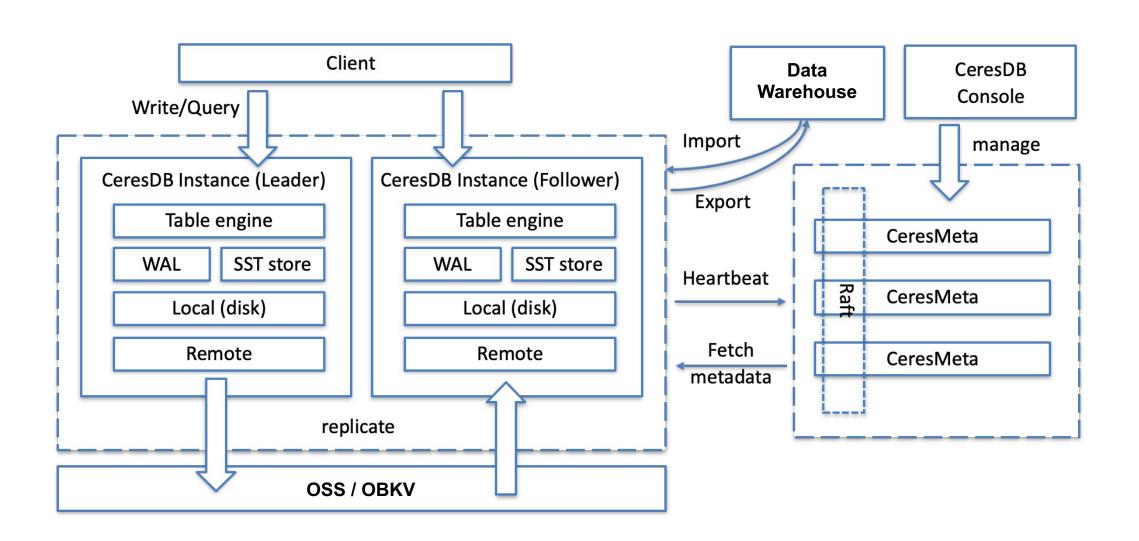
#### 3. 使用成熟开源技术

- Parquet 的实现 SST
- SQL 执行与优化使用了 DataFusion , 并进行了一定的扩展



# 时序数据库 CeresDB——分布式架构





# 时序数据库 CeresDB——性能优化(查询)



#### 计算存储分离的数据优化思路

#### 1. 针对超大数据表(百亿级)

• 增加水平扩展性: CeresDB 支持分区表

#### 2. 存算分离特有问题

• 首查性能

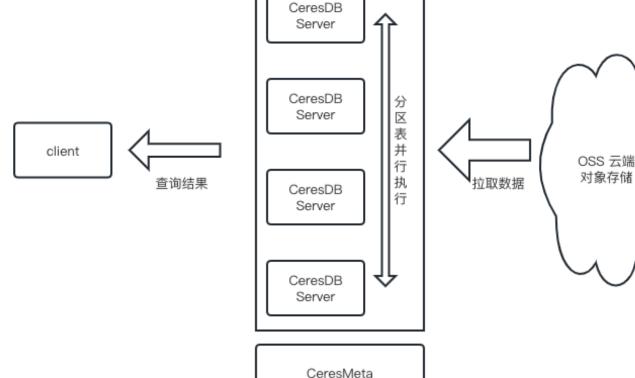
• 数据拉的更少:筛选度问题

· 数据拉的更快:远程IO并行度

- 次查性能
  - 多级缓存层次的构建

#### 3. 性能的一致性

- 后台任务的影响
  - Compaction 内存与 CPU 开销的限制
- 突发烂 SQL 的影响
  - 烂 SQL 的识别
  - SQL 黑名单



### 未来计划



### 一段话:

从开源中汲取养分,同时将我们的思考也贡献给开源。我们将开放蚂蚁在可观测领域的所有技术,与社区共建,创造共同价值。

### 两个项目:

- · CeresDB【已开源】:
  - 高性能云原生时序数据库
- HoloInsight【筹备中,2月开源】:
  - 一站式智能可观测平台





### **GitHub:**

https://github.com/CeresDB/ceresdb

### 微信群:





Valid until 1/17 and will update upon joining group

### 钉钉群:





# THANKS / 感谢!